浙江大學

课程综合实践
实验报告

实验名称 简单 CNN 网络训练

姓名学号 陶泓宇 3200103929

实验日期 2021 年 8 月 4 日

目录

插图

1 实验目的和要求

本次实验我们将完成两个简单的 CNN 网络，并在 GPU 上加速它的训练，体会基本的网络设计、训练流程。

2 卷积神经网络基本构成

2.1 卷积层

卷积层主要用于提取图像特征。

卷积层进行的处理就是卷积运算。卷积运算相当于图像处理中的“滤波器运算”。对于输入数据，卷积运算以一定间隔滑动滤波器的窗口并应用；将各个位置上滤波器的元素和输入的对应元素相乘，然后再求和。然后，将这个结果保存到输出的对应位置。将这个过程在所有位置都进行一遍，就可以得到卷积运算的输出。

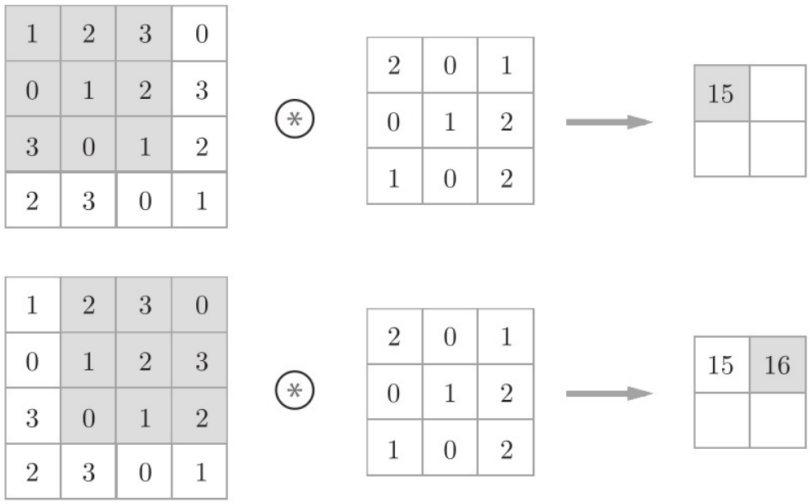

图 1: 卷积运算示意图

在 pytorch 中搭建卷积层采用以下代码：

```
nn.Conv2d(1,6,kernel_size=5,stride=1,padding=2)
```

第一个参数是输入通道数，第二个参数是输出通道数，第三个参数是卷积核尺寸，第四个参数是步长，第五个参数是填充层数；设原图尺寸为 n x n；卷积核尺寸为 f x f ；padding 为 p，stride 为 s，输出图像像素表达式：[(n+2p-f)/s +1] x [(n+2p-f)/s +1]

2.2 池化层

池化用于降低卷积层输出的特征维度，在减少网络参数的同时还能防止过拟合；最大池化示意图如下：

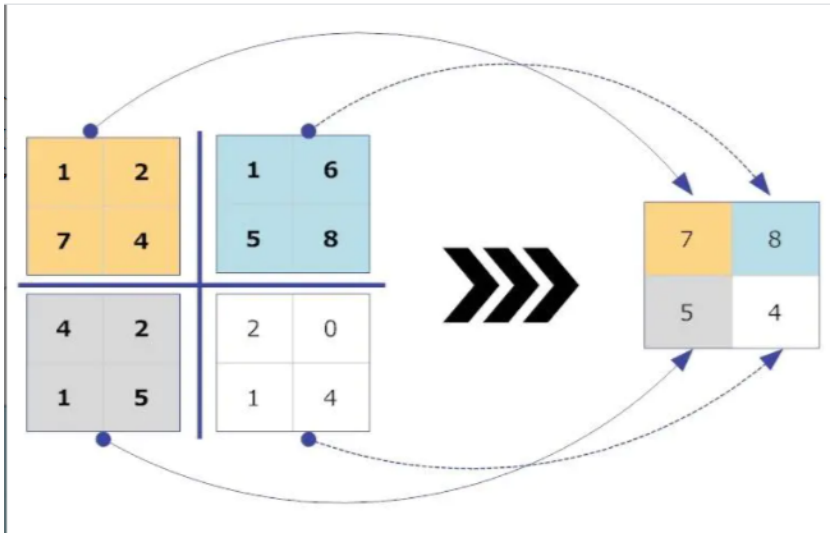

图 2: 最大值池化示意图

在 pytorch 中搭建池化层采用以下代码：

```
nn.MaxPool2d(kernel_size=2,stride=2,padding=0)
```

第一个参数是卷积核的尺寸，第二个参数是步长，第三个参数是填充层数。

2.3 全连接层

全连接层用于组合之前提取到的所有特征，为了提升 CNN 网络性能，全连接层每个神经元的激励函数一般采用 ReLU 函数。全连接层示意图如下：

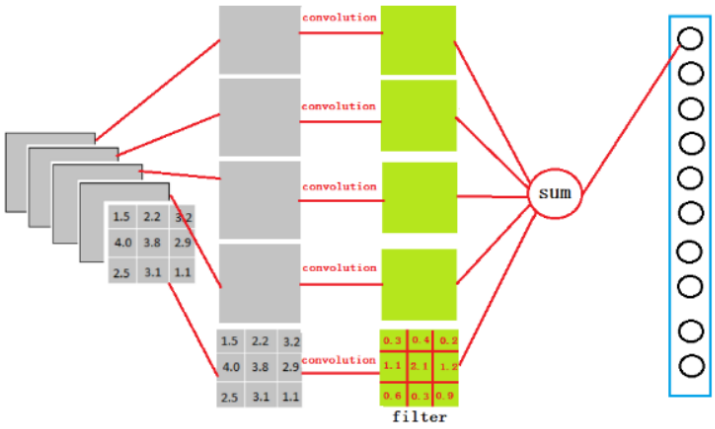

图 3: 全连接层示意图

在 pytorch 中搭建全连接层采用以下代码：

```
        self.fc1 = nn.Sequential(
            nn.Linear(16*5*5,120),
            nn.ReLU()
        )
        self.fc2 = nn.Sequential(
            nn.Linear(120,84),
            nn.ReLU()
        )
        self.fc3 = nn.Linear(84,19)
```

nn.linear() 函数中第一个参数是输入的二维张量的大小，第二个参数是输出的二维张量的大小

3 实验内容和原理

3.1 LeNet5 神经网络

LeNet5 神经网络的 python 代码截图如下：

```python
class LeNet(nn.Module):
    def __init__(self):
        super(LeNet,self).__init__()
        #卷积层与池化层
        self.conv1 = nn.Sequential(
            #卷积层，输入通道数为1，输出通道数为6，卷积核大小为5x5，步长为1，填充两层
            nn.Conv2d(1,6,kernel_size=5,stride=1,padding=2),#输出仍为nxn大小的矩阵
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2,stride=2,padding=0)
        )
        self.conv2 = nn.Sequential(
            nn.Conv2d(6,16,kernel_size=5,stride=1,padding=0),
            nn.ReLU(),
            nn.MaxPool2d(kernel_size=2,stride=2,padding=0)
        )

        #全连接层
        self.fc1 = nn.Sequential(
            nn.Linear(16*5*5,120),
            nn.ReLU()
        )
        self.fc2 = nn.Sequential(
            nn.Linear(120,84),
            nn.ReLU()
        )
        self.fc3 = nn.Linear(84,19)
    def forward(self,x):
        x = self.conv1(x)
        x = self.conv2(x)

        x = x.view(x.size(0), -1) #全连接层均使用的nn.Linear()线性结构，输入输出维度均为一维，故需要把数据拉为一维
        x = self.fc1(x)
        x = self.fc2(x)
        x = self.fc3(x)
        return x
```

图 4: LeNet5 实现代码截图

self.conv1 与 self.conv2 分别定义了两个卷积层 + 池化层的类。

```
nn.Conv2d(1,6,kernel_size=5,stride=1,padding=2),
#输出仍为nxn大小的矩阵
nn.ReLU(),
nn.MaxPool2d(kernel_size=2,stride=2,padding=0)
```

上述代码定义了第一个卷积层与第一个池化层，卷积层的输入通道为 1（灰度图像），由于卷积核为 5x5 且步长为 1，输出通道数为 6；nn.ReLu() 采用 ReLu 作为激活函数；池化层则采用最大池化，取 2x2 矩阵中的最大值合成得到新矩阵。

```
nn.Conv2d(6,16,kernel_size=5,stride=1,padding=0),
nn.ReLU(),
nn.MaxPool2d(kernel_size=2,stride=2,padding=0)
```

第二个卷积层与池化层也类似

self.fc 定义了全连接层，采用 ReLu 激活函数来获取相应的输出矩阵

```
    def forward(self,x):
        x = self.conv1(x)
        x = self.conv2(x)

        x = x.view(x.size(0), -1)
#全连接层均使用的nn.Linear()线性结构，
#输入输出维度均为一维，故需要把数据拉为一维
        x = self.fc1(x)
        x = self.fc2(x)
        x = self.fc3(x)
```

上述代码则定义了前向传播的过程。

下面是 main.py 文件中部分代码截图：

```
#load data
transform = torchvision.transforms.ToTensor()   #定义数据预处理方式：转换 PIL.Image 成 torch.FloatTensor

train_data = torchvision.datasets.MNIST(root="F:\\桌面\\data",    #数据目录，这里目录结构要注意。
                                        train=True,                                         #是否为训练集
                                        transform=transform,                                #加载数据预处理
                                        download=False)                                     #是否下载
test_data = torchvision.datasets.MNIST(root="F:\\桌面\\data",
                                       train=False,
                                       transform=transform,
                                       download=False)
#数据加载器:组合数据集和采样器
train_loader = torch.utils.data.DataLoader(dataset = train_data,batch_size = 64,shuffle = True)
test_loader = torch.utils.data.DataLoader(dataset = test_data,batch_size = 64,shuffle = False)

#define loss
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")   #若检测到GPU环境则使用GPU，否则使用CPU
net = LeNet().to(device)    #实例化网络，有GPU则将网络放入GPU加速
loss_fuc = nn.CrossEntropyLoss()    #多分类问题，选择交叉熵损失函数
optimizer = optim.SGD(net.parameters(),lr = 0.001,momentum = 0.9)   #选择SGD，学习率取0.001
```

图 5: 训练过程代码截图

采用 torchvision.datasets.MNIST 来读取数据与划分测试集与训练集。

```
train_data = torchvision.datasets.MNIST
(root="F:\\桌面\\data",
train=True,
transform=transform,
download=False)
test_data = torchvision.datasets.MNIST
(root="F:\\桌面\\data",
train=False,
transform=transform,
download=False)
```

采用 torch.utils.data.DataLoader 来读取数据，dataset 参数指定读取的数据集，batch size 指定一次读取的数据数量，shuffle=True 时随机打乱数据。

```
train_loader = torch.utils.data.DataLoader
(dataset = train_data,batch_size = 64,shuffle = True)
test_loader = torch.utils.data.DataLoader
(dataset = test_data,batch_size = 64,shuffle = False)
```

若检测到 GPU 环境则使用 GPU，否则使用 CPU

```
device = torch.device
("cuda" if torch.cuda.is_available() else "cpu")
net = LeNet().to(device)
```

选择交叉熵损失函数作为损失函数

```
device = torch.device
loss_fuc = nn.CrossEntropyLoss()
```

选择 SGD（随机梯度下降）作为优化器，net.parameter 获取 net 网络的参数，lr 指定学习率，momentum 表示冲量

```
optimizer = optim.SGD
(net.parameters(),lr = 0.001,momentum = 0.9)
```

训练时采用梯度清零的方式进行训练，设定训练的 epoch 为 64，每 100 个 batch 打印一次平均 loss。

```python
#开始训练
EPOCH = 64   #迭代次数
for epoch in range(EPOCH):
    sum_loss = 0
    #数据读取
    for i,data in enumerate(train_loader):
        inputs,labels = data
        inputs, labels = inputs.to(device), labels.to(device)   #有GPU则将数据置入GPU加速

        # 梯度清零
        optimizer.zero_grad()

        # 传递损失 + 更新参数
        output = net(inputs)
        loss = loss_fuc(output,labels)
        loss.backward()
        optimizer.step()

        # 每训练100个batch打印一次平均loss
        sum_loss += loss.item()
        if i % 100 == 99:
            print('[Epoch:%d, batch:%d] train loss: %.03f' % (epoch + 1, i + 1, sum_loss / 100))
            sum_loss = 0.0

    correct = 0
    total = 0

    for data in test_loader:
        test_inputs, labels = data
        test_inputs, labels = test_inputs.to(device), labels.to(device)
        outputs_test = net(test_inputs)
        _, predicted = torch.max(outputs_test.data, 1)  #输出得分最高的类
        total += labels.size(0) #统计50个batch 图片的总个数
        correct += (predicted == labels).sum()  #统计50个batch 正确分类的个数
    print('第{}个epoch的识别准确率为：{}%'.format (epoch + 1, 100*correct.item()/total))
```

图 6: 训练过程代码截图

3.2 ResNet18 网络

在构建训练 cifar10 的神经网络，我参考了 LesNet18 网络，根据简书上的一张图搭建了 ResNet18 网络，原图如下，但我发现输入的图像尺寸是 3x32x32，并不是图中所说的 3x224x224，因此，我去掉了最后的那个卷积核大小为 7 的平均池化层。

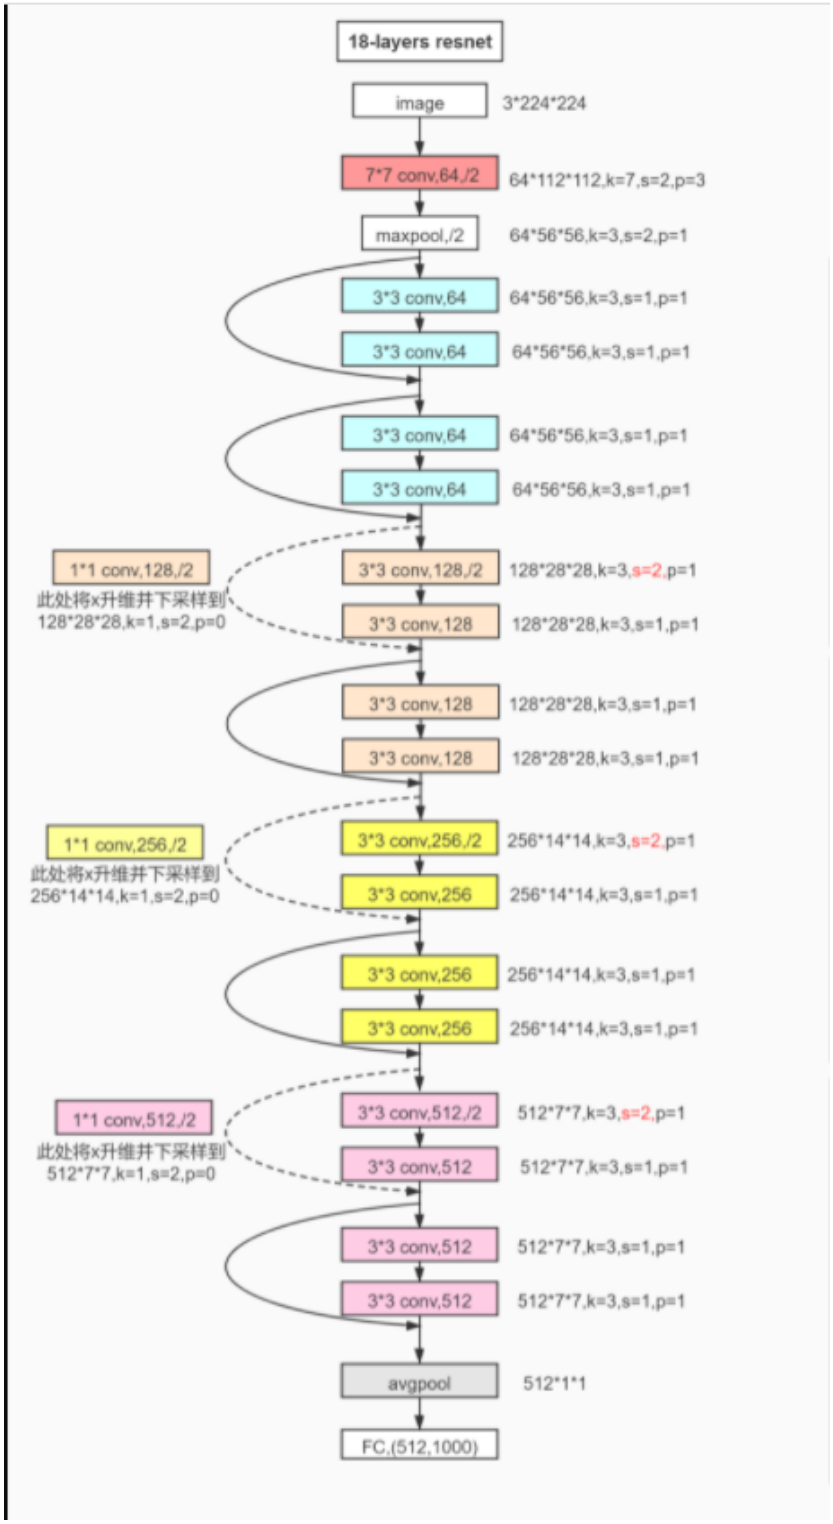

图 7: ResNet18 示意图

ResNet18 的作者提出的结构图如下图左侧 18-layers 对应的那一列：

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 64 \\ 3\times3, 64 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$
conv3_x	28×28	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 128 \\ 3\times3, 128 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times8$
conv4_x	14×14	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 256 \\ 3\times3, 256 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times23$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times36$
conv5_x	7×7	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times2$	$\begin{bmatrix} 3\times3, 512 \\ 3\times3, 512 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

图 8: ResNet18 结构图

该网路共 17 个卷积层，1 个全连接层，第一个卷积层没有 shortcut 机制，之后接的几个卷积层都有 shortcut 机制，最后再接一个全连接层。

ResNet18 的代码实现截图如下：

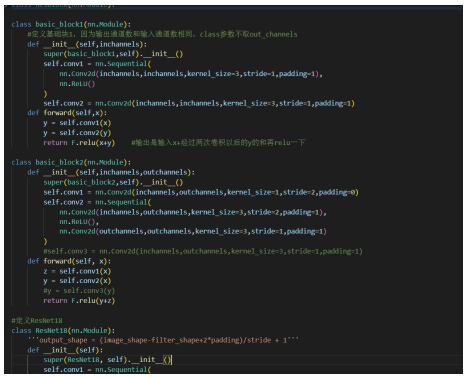

```
class basic_block1(nn.Module):
    #定义基础块1，因为输出通道数和输入通道数相同，class参数不取out_channels
    def __init__(self,inchannels):
        super(basic_block1,self).__init__()
        self.conv1 = nn.Sequential(
            nn.Conv2d(inchannels,inchannels,kernel_size=3,stride=1,padding=1),
            nn.ReLU()
        )
        self.conv2 = nn.Conv2d(inchannels,inchannels,kernel_size=3,stride=1,padding=1)
    def forward(self,x):
        y = self.conv1(x)
        y = self.conv2(y)
        return F.relu(x+y)    #输出是输入x+经过两次卷积以后的y的和再relu一下

class basic_block2(nn.Module):
    def __init__(self,inchannels,outchannels):
        super(basic_block2,self).__init__()
        self.conv1 = nn.Conv2d(inchannels,outchannels,kernel_size=1,stride=2,padding=0)
        self.conv2 = nn.Sequential(
            nn.Conv2d(inchannels,outchannels,kernel_size=3,stride=2,padding=1),
            nn.ReLU(),
            nn.Conv2d(outchannels,outchannels,kernel_size=3,stride=1,padding=1)
        )
        #self.conv3 = nn.Conv2d(inchannels,outchannels,kernel_size=3,stride=1,padding=1)
    def forward(self, x):
        z = self.conv1(x)
        y = self.conv2(x)
        #y = self.conv3(y)
        return F.relu(y+z)

#定义ResNet18
class ResNet18(nn.Module):
    '''output_shape = (image_shape-filter_shape+2*padding)/stride + 1'''
    def __init__(self):
        super(ResNet18, self).__init__()
        self.conv1 = nn.Sequential(
```

图 9: ResNet18 代码实现截图

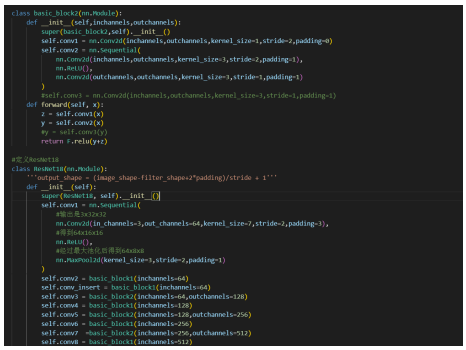

图 10: ResNet18 代码实现截图

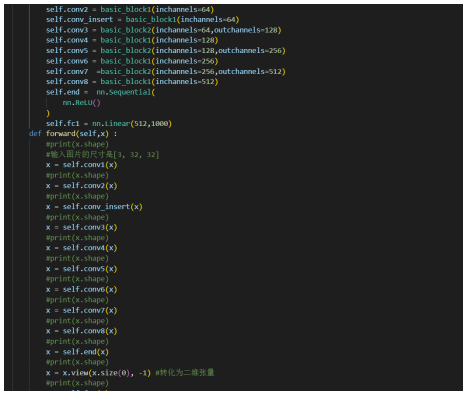

图 11: ResNet18 代码实现截图

main_cifar10.py 文件与 main_minist.py 文件类似：

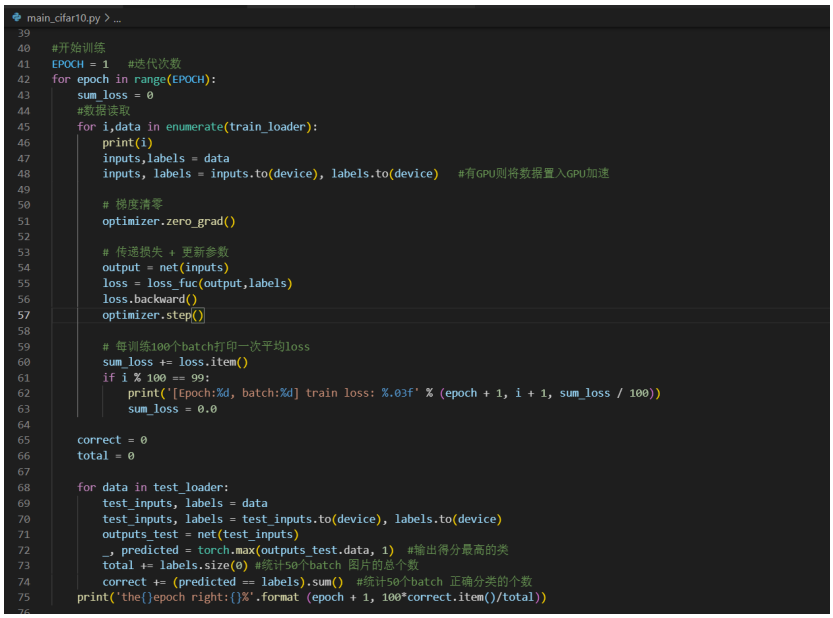

图 12: main_cifar10 文件截图

训练的损失函数取 nn.CrossEntropyLoss()，优化器取 SGD，学习率取 0.01

4 实验数据记录和处理

4.1 MNIST

100 个 epoch 后 LeNet 网络的损失函数如下图所示：

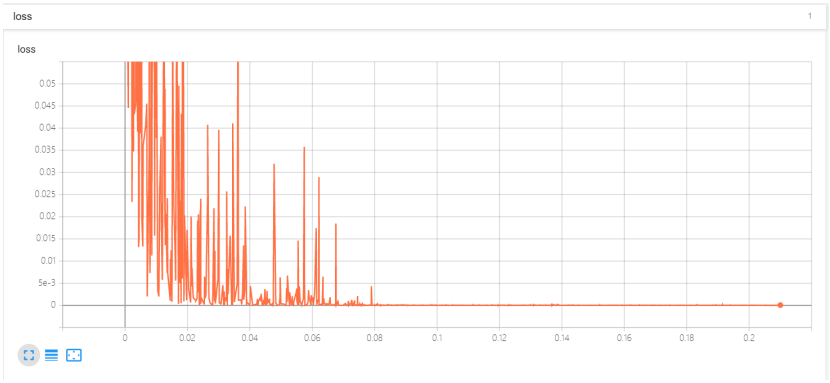

图 13: mnist 损失函数

GPU 利用情况截图如下：

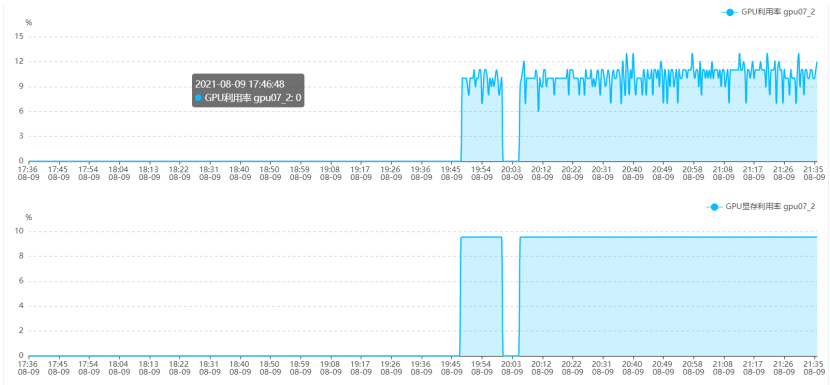

图 14: GPU 利用情况截图

识别正确率如下：

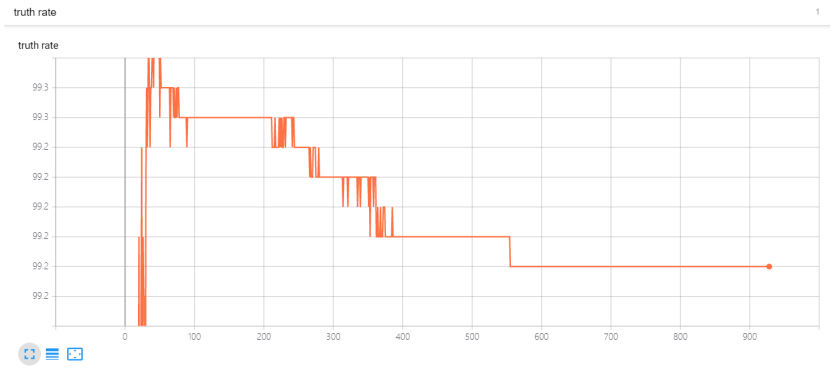

图 15: mnist 识别正确率

4.2 CIFAR10

训练时的 GPU 利用情况如下：

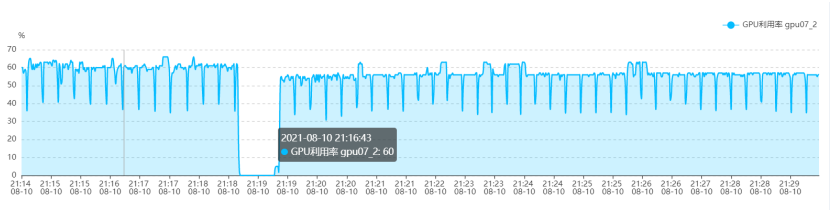

图 16: cifar10GPU 利用情况

识别正确率如下：

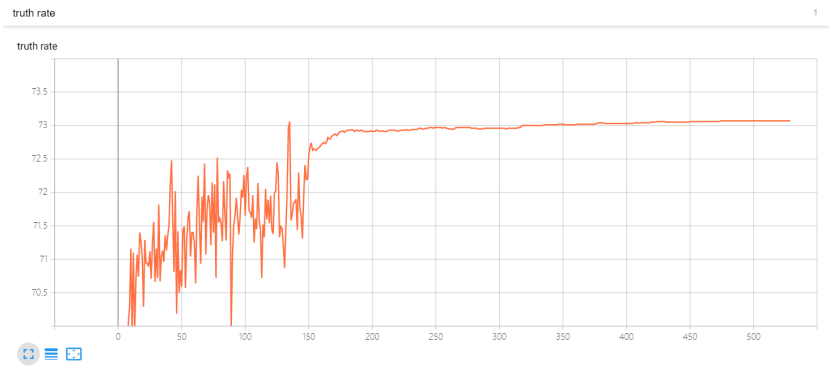

图 17: cifar10 识别率曲线

loss 函数曲线如下：

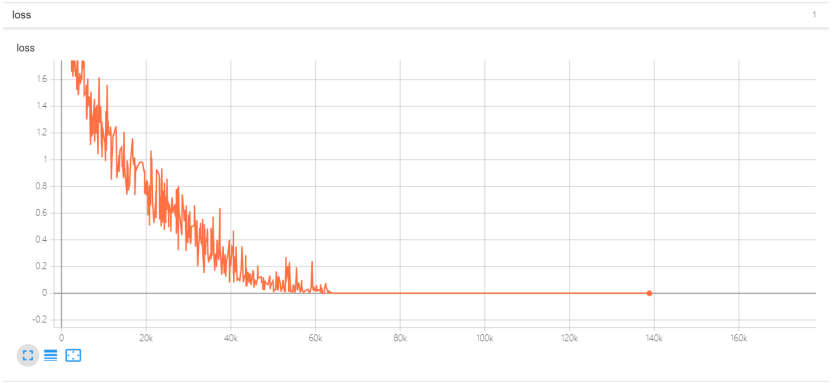

图 18: cifar10-loss 曲线

5 讨论、心得

Q: 池化层有很多种，较常使用的是平均和最大，在这个数据集上使用有什么的区别，哪个效果好一些？

A: 平均值池化取平均值，保留了背景特征，但容易模糊图像，最大值池化则保留纹理特征，在 MNIST 中采取最大池化以保留文字边缘特征，而在 CIFAR10 中则采取平均值池化以获取背景特征（图像较为复杂）。

Q：你采用了哪些策略来改进你的网络，效果如何？

A: 在进行 cifar10 的识别的时候，尝试了各种优化方法，使用 Adamax 时，最开始的识别准确率比 SGD 要高，但最后收敛在百分之 57 的正确识别率上，在使用 SGD 时，还尝试了调整学习率，在 30 个 epoch 后，学习率取 0.01 的识别正确率在百分之 70 左右，而取 0.02 时识别正确率在百分之 67 左右, 学习率取 0.001 时识别正确率可以收敛在百分之 75.

6 参考资料

[1] 卷积神经网络 LeNet-5 的 pytorch 代码实现（LeNet5 与 main 函数的编写很大程度上参考了这篇博客）

https://blog.csdn.net/didi_ya/article/details/108317958

[2] 深度学习小白实现残差网络 resnet18 ——pytorch

https://blog.csdn.net/weixin_44331304/article/details/106127552

[3] Pytorch 实战 2：ResNet-18 实现 Cifar-10 图像分类

https://blog.csdn.net/sunqiande88/article/details/80100891

[4] resnet18 50 网络结构以及 pytorch 实现代码

https://www.jianshu.com/p/085f4c8256f1

[5] 通过 Pytorch 实现 ResNet18

https://zhuanlan.zhihu.com/p/157134695

7 容器基本信息

因为怕删掉原来 tensorflow 的容器以后再申请 pytorch 的容器会花很久，我就直接在原始容器上面安装了 pytorch，容器信息如下：

环境名称	20210723153248_thy	创建时间	2021-07-23 15:33:11
镜像	10.202.210.100:5000/tensorflow/tensorflow:1.14-cuda10-py36	状态	运行中
资源组	Tra_group_chenjh	GPU	GeForce RTX 2080 Ti:1
CPU	4	挂载路径	/chenjh08
副本数	1	shm_size	TotalMemory/2
数据集路径			

图 19: 容器信息